PPML / Secure Inference 博士阶段方向搭建与研究路线

赵帅

2026-04-24

目录

1 执行假设与范围界定 **2**
1.1 执行假设 2
1.2 方向判断 2
1.3 推荐主线与不建议先深挖的支线 2

2 总路线图 **2**

3 按天计划（56 天） **3**

4 实验路线 **9**
4.1 E1: MP-SPDZ 微基准 9
4.2 E2: MP-SPDZ 小模型推理 9
4.3 E3: OpenFHE/SEAL 算子基准 9
4.4 E4: Concrete ML FHE 与模拟 9
4.5 E5: MPC-only vs HE-only vs Hybrid 对比 9
4.6 E6: Transformer block 成本台账 10
4.7 E7: 选题前消融 10
4.8 E8: 研究设计最小验证 10

5 每日笔记模板 **10**

6 压缩版计划（3–5 小时/天） **11**

7 服务器配置建议 **12**

8 50+ 论文附录 **12**

9 结语 **15**

执行假设与范围界定

执行假设

- 默认完整计划为 56 天连续 bootstrapping，日均 6–8 小时；压缩版按 3–5 小时/天单独给出。
- 研究主线限定为 secure inference，不把 secure training、FL、TEE 作为首阶段主线，只在比较时补充。
- 实验锚点优先选 MP-SPDZ + OpenFHE / SEAL / Concrete ML + SPU / OpenBumbleBee。
- 目标不是“知道很多名词”，而是尽快建立：比较能力、复现实验能力、瓶颈拆解能力、形成选题能力。

方向判断

方向	匹配度	判断
MPC inference	最高	与你已有 MP-SPDZ 经验直接衔接，最容易快速获得“可跑、可比、可拆瓶颈”的研究起点。
Hybrid secure inference	很高	你可以把 MPC 作为锚点，再把 HE 作为线性层优化器来理解；这条线更容易形成系统论文问题。
HE inference	中高	必须学，但不建议一开始走纯 HE 深水区；否则容易被参数、bootstrapping、编译器细节拖慢形成题目的速度。
系统优化	很高	这不是独立 primitive，而是长期主镜头：转换、打包、近似、编译、GPU、缓存/通信都在这里。
Secure LLM inference	中等（作为起步偏难）	建议作为第 3 阶段应用面进入，而不是第 1 阶段主线；仓库和实验复杂度显著更高。

推荐主线与不建议先深挖的支线

- 主线：MPC inference $ ightarrow$ Hybrid secure inference $ ightarrow$ Transformer/LLM secure inference 中的系统优化问题。
- 支线 1：HE inference 工程能力（CKKS、packing、rotation、rescale、compiler/runtime）。
- 支线 2：编译/运行时框架（SPU、OpenFHE、Concrete ML）的系统化理解。
- 先不建议重押：纯 bootstrapping/硬件加速细节、secure training、大模型端到端复现、CrypTen-centric 路线。

总路线图

阶段	目标	输入	输出	风险	通过标准
P1	补图谱	经典论文、框架文档	领域地图、术语表	只看论文不落地	能画出 primitive–operator–system 图
P2	读代表作	SecureML–Cheetah、CKKS–EVA、SPU	代表系统卡片	陷入碎片阅读	能比较不同路线优缺点
P3	跑框架	MP-SPDZ、OpenFHE、Concrete ML、SPU	可复现实验脚本	环境问题拖慢节奏	至少跑通 3 条最小链路
P4	做比较	同任务、同指标、同威胁模型对比	对比矩阵、图表	不公平比较	能把差异归因到算子/表示
P5	找切口	瓶颈分解、消融、候选题	研究备忘录、未来 4 周 backlog	题目过大过散	能给出 1 主 1 备选题

按天计划（56 天）

Day	时长	阅读	文档/代码	实验与产出	必懂/自测
1	6h	Survey on PPML inference 的 Intro/Taxonomy/Challenges；MP-SPDZ Getting Started；SecureML 的 Intro、System Model、Evaluation 主结果。	MP-SPDZ docs index / Getting Started / Programs/Source/tutorial.mpc	安装并跑通 tutorial，记录可用协议和运行入口。；产出：威胁模型矩阵 v1 + 环境日志。	必懂：offline/online、semi-honest vs malicious、算术/布尔共享。；自测：能解释为什么线性层更适合算术共享。
2	6h	SecureML 的 Building Blocks 与主实验；MiniONN 的 Intro、Transformation、Evaluation。	论文笔记目录；MiniONN 代码仓库（若不跑则只看 README/目录）。	把两篇论文按“线性/非线性/模型保护”拆成对比表。；产出：SecureML vs MiniONN 对比表。	必懂：MiniONN 为什么比通用 2PC 更快。；自测：能说清 MiniONN 的转换思想。
3	6h	ABY3 的 Intro、Protocol Overview、fixed-point/Truncation 相关部分、Evaluation；SecureNN 的 Building Blocks 与主结果。	ABY3 仓库 README；SecureNN 论文。	手工画出 truncation、ReLU、matmul 在两者中的实现路径。；产出：3PC 协议卡片 2 张。	必懂：3PC 为什么对 PPML 友好。；自测：能比较 ABY3 与 SecureNN 的安全/效率侧重点。

4	6h	Gazelle 的 System Overview、HE kernels、switching protocol、Evaluation；Chameleon 的 Intro、Hybrid design、Evaluation。	Gazelle/Chameleon 论文；Gazelle 相关代码目录（若可得）。	画出 HE GC/HE MPC 切换位置图。；产出：Hybrid 设计图 v1。	必懂：为何混合系统常把线性与非线性拆开。；自测：能指出转换成本为什么会吞掉收益。
5	6h	XONN 的 Intro、binarization/XNOR 思想、Evaluation；Delphi 的 Intro、hybrid protocol、approximation、Evaluation。	XONN/Delphi 论文与仓库 README。	整理“近似换效率”与“结构换效率”两类路线。；产出：方法学对比表 v1。	必懂：binarization 与 polynomial approximation 的本质差别。；自测：能说清 XONN 适用边界。
6	6h	CrypTFlow2 的 comparison/division 协议与 Evaluation；Cheetah 的 linear/nonlinear protocols、artifact 说明与主实验。	CrypTFlow2 paper + Microsoft page；Cheetah artifact appendix/README。	列出 ImageNet 级模型进入 secure inference 时新增的工程问题。；产出：规模化问题清单。	必懂：为什么 comparison/division 是系统瓶颈。；自测：能解释 CrypTFlow2 与 Cheetah 的优化点。
7	5h	回看第 1 周所有笔记；补读遗漏的 threat model、evaluation setup。	你本周的笔记仓库。	不跑新代码，只做一次 20 分钟口头复盘。；产出：“经典 PPML 系统地图”一页图。	必懂：协议选择和威胁模型之间的关系。；自测：闭卷画出 2017–2022 代表系统演化线。
8	6h	MP-SPDZ 文档：Getting Started、Compilation、Running Computations、Overview。	Programs/Source/tutorial.mpc、Compiler/；Scripts/。	重新编译并跑 tutorial，试至少 2 种协议。；产出：MP-SPDZ 运行手册 v1。	必懂：编译期与运行期分别做什么。；自测：能说明 compile.py 与在线执行的职责分离。
9	6h	MP-SPDZ 文档：Preprocessing、Protocols、dishonest majority vs honest majority、混合算术/二进制共享。	Protocols/、Processor/、Machines/、Scripts/benchmarking。	记录各协议的预处理依赖、通信模式、适用安全模型。；产出：协议选择表 v1。	必懂：OT/HE 预处理在系统里扮演什么角色。；自测：能根据任务选 semi2k / mascot / rep3 等代表协议。
10	6h	Machine Learning Quickstart；Machine Learning 文档中的 PyTorch interface、layers_from_torch、torch_mnist_dense 示例。	Programs/Source/torch_mnist_dense.mpc、相关 PyTorch 接口说明。	跑通一个官方小模型例子。；产出：MP-SPDZ ML 快速上手笔记。	必懂：PyTorch 网络如何被映射到 MPC 图。；自测：能说出支持层/不支持层的界限。
11	6h	MP-SPDZ 固定点/浮点文档与相关源代码；复读 ABY3/CrypTFlow2 的 truncation 描述。	Compiler/types.py；Math/；相关 truncation 实现位置。	做微基准：加法、乘法、比较、ReLU、truncate。；产出：算子成本表 v1。	必懂：哪类算子最吃通信，哪类最吃本地计算。；自测：能按算子给出‘便宜/昂贵’排序。
12	6h	MP-SPDZ 中关于二进制/算术混用、比较、bit decomposition 的文档或代码位置。	Compiler/、Protocols/、GC/。	做维度 sweep：向量长度、矩阵尺寸、batch size 小规模扫描。；产出：维度-开销曲线 v1。	必懂：成本随维度增长的主导项是什么。；自测：能预判某实验是通信受限还是计算受限。
13	6h	Machine Learning 文档中 SGD/MNIST 相关部分；查看已有示例的训练/推理差别。	torch_mnist_dense、mnist/logreg 示例；Scripts。	把一个明文小模型导入 MP-SPDZ 并只做推理。；产出：模型导入记录。	必懂：安全训练与安全推理的工程差异。；自测：能说明为什么当前主线先只做 inference。

14	5h	回看第 2 周所有实验日志；补读 MP-SPDZ Homomorphic Encryption 文档了解其在预处理中的角色。	Utils/he-example.cpp；HE 文档。	整理一份“MP-SPDZ 内部心智模型”。；产出：MP-SPDZ 架构图。	必懂：MP-SPDZ 是协议实验底座，而非单一算法论文代码。；自测：能解释它为什么适合作为你的锚点。
15	6h	CKKS 论文的近似数编码/尺度/rescale 核心部分；HomomorphicEncryption.org standard 页面。	OpenFHE docs 首页与 Security Notes。	写一页 CKKS 心智模型，不跑代码或只跑最小示例。；产出：CKKS 速查表。	必懂：scale、level、noise budget 的区别。；自测：能解释为什么 CKKS 适合近似推理。
16	6h	OpenFHE docs：Using the Library、Examples、CryptoContext 相关；SEAL README。	OpenFHE src/examples/pke；SEAL examples。	跑最小 CKKS 示例：encode/encrypt/add/mul/rotate/decrypt。；产出：OpenFHE hello-fhe 日志。	必懂：CryptoContext 负责什么。；自测：能追踪一次 mul+rescale 后参数变化。
17	6h	OpenFHE Security Notes；OpenFHE examples 中 CKKS/rotation/key switching。	OpenFHE security notes；src/examples/pke。	做微基准：乘法、rotation、rescale、keyswitch。；产出：HE 算子成本表 v1。	必懂：为什么 rotation/keyswitch 常成为 HE 线性层瓶颈。；自测：能比较 add/mul/rotate 的相对代价。
18	6h	CryptoNets、LoLa、CHET：各读 Intro/System design/Evaluation。	CHET/EVA 论文与开源资料。	按‘模型改造 vs 编译优化 vs 参数选择’三类归纳。；产出：HE 推理方法学表。	必懂：为什么 FHE 常要求改模型或改激活。；自测：能指出 CryptoNets→LoLa→CHET 的演化逻辑。
19	6h	EVA 论文的 IR/优化/与 CHET 对比部分；OpenFHE library paper 的设计原则。	EVA 论文；OpenFHE paper。	把“编译器视角”加入你的图谱：布局、参数、算子融合。；产出：HE 编译器视角笔记。	必懂：为何 HE 研究常以 compiler/runtime 形式出现。；自测：能解释 CHET 与 EVA 的分工差异。
20	6h	Concrete ML docs：Quickstart、Prediction with FHE、Debugging models。	Concrete ML docs；本地 notebook。	跑一个 toy model 的 compile/simulate/FHE predict（若环境失败则只做 simulate）。；产出：Concrete ML 上手记录。	必懂：simulate 与真正 FHE 执行的关系。；自测：能解释 quantization 对 FHE 电路的作用。
21	5h	回看第 3 周；补读 OpenFHE/Concrete ML 的 Hybrid/GPU 部分标题与结构。	你的 HE 笔记仓库。	不追新结果，整理‘HE-only 的长短板’。；产出：HE-only 风险清单。	必懂：何时 HE-only 值得用，何时不值得。；自测：能给出 3 个适合 HE-only 的任务特征。
22	6h	Concrete ML：Hybrid Models、Security and correctness、Production deployment。	Concrete ML Hybrid docs。	做一次小模型 split 方案设计（客户端明文前层 / FHE 后层，或相反的思考实验）。；产出：Hybrid split 方案 v1。	必懂：split 位置为什么不是拍脑袋选。；自测：能用延迟/泄露面/精度三维评估 split。
23	6h	Gazelle、Delphi、CrypTFlow2 再读一遍，只看混合边界与转换细节。	三篇论文的 system/protocol sections。	统计每个系统在哪些层做协议切换。；产出：Hybrid conversion 对照表。	必懂：一次转换到底改变了什么表示/精度/位宽。；自测：能描述至少两类 conversion。

24	6h	TenSEAL README / tutorials（只作为直觉工具，不作为主平台）。	TenSEAL examples；SEAL/TenSEAL Python API。	用 Python 体验 CKKS tensor/bfv vector 的最小操作。；产出：TenSEAL 直觉笔记。	必懂：为什么它适合建立直觉，不适合做主线研究平台。;自测:能说清 SEAL/OpenFHE/TenSEAL 的关系。
25	6h	Simulating Homomorphic Evaluation、AutoFHE、LOHEN：读问题定义、优化目标、主实验。	相关论文与代码 README。	把‘近似/bootstrapping/层级优化’放进 HE 研究问题表。；产出：HE 优化问题清单。	必懂：如何在性能与精度之间做系统化 trade-off。；自测：能解释 layer-wise optimization 的价值。
26	6h	OpenFHE / Concrete ML 再看 packing、debugging、security notes。	OpenFHE examples；Concrete ML debugging。	设计一个统一实验：同一 toy MLP 的明文、HE 模拟、HE 真执行（若可）。；产出：统一 toy benchmark 设计书。	必懂：公平比较需要固定哪些变量。；自测：能列出至少 6 个 fairness 控制项。
27	6h	回看 Hybrid 经典系统与 HE 优化论文。	你的方法学笔记。	为一个 2-layer MLP 人工设计 3 种执行方案：MPC-only、HE-only、Hybrid。；产出：方案比较表 v1。	必懂：为什么很多好论文其实在做 representation engineering。；自测：能给出你自己的 hybrid cut 选择理由。
28	5h	整合前四周。	笔记仓库与实验日志。	不跑新框架，完成第一次阶段总结。；产出：《前四周总结：我能比较什么，不能比较什么》。	必懂：当前图谱中的空白在哪里。；自测：能写出 3 个你想测但还没测的瓶颈问题。
29	6h	SPU docs：What is SPU、Getting Started、Quickstart、Architecture。	SPU docs；examples/；repo README。	安装或最少跑通 quickstart（若环境太重则做代码结构阅读）。；产出：SPU 上手笔记。	必懂：compiler IR 和 runtime 分层意味着什么。；自测：能解释 SPU 与 MP-SPDZ 的定位差异。
30	6h	SecretFlow-SPU 论文：Intro、architecture、evaluation；再读 SPU docs。	SPU paper；docs。	把 SPU 与 CrypTen 风格 API/编译式框架做对比。；产出：框架谱系图。	必懂：为什么‘用户友好’会成为研究问题。；自测：能说明 compiler-based PPML 的价值。
31	6h	Piranha、CryptGPU：读 GPU acceleration 设计与实验。	论文/仓库 README。	不必真跑 GPU；先做 CPU/GPU 适配点清单。；产出：GPU 适配清单。	必懂：哪些 MPC/PPML 操作天然适合 GPU。；自测：能说清 GPU 为什么主要帮助线性层。
32	6h	ASTRA、FLASH、FALCON、Meteor：各读 Intro、building blocks、Evaluation。	四篇论文。	把 honest-majority 3PC/4PC 路线与 2PC 路线分开整理。；产出：party-model 对比表。	必懂：为什么 party model 一变，系统设计就变。；自测：能区分 2PC 与 3PC 的常见工程收益。

33	6h	回看第 5 周论文与前面所有 benchmark 设计。	你的 benchmark 草案。	确定正式比较矩阵：协议 × 安全模型 × 算子 × 任务 × 指标。；产出：比较矩阵 v1。	必懂：指标不统一会怎样误导结论。；自测：能给出一套你认可的公平比较模板。
34	6h	只补读与你比较矩阵相关的文档片段。	MP-SPDZ、OpenFHE/Concrete、SPU 相关 docs。	跑 controlled comparison #1：同一 toy MLP 的 MPC-only vs HE-sim/HE-only。；产出：首版对比结果。	必懂：为什么不追求绝对数字，而要追求可解释差异。；自测：能把结果归因到算子与表示。
35	5h	复盘第 5 周所有结果。	实验日志。	写一份瓶颈备忘录：通信、近似、转换、rotation、预处理。；产出：瓶颈备忘录 v1。	必懂：哪个瓶颈最值得你后续追。；自测：能选出一个首要瓶颈并给理由。
36	6h	Private Transformer Inference survey 与 2026 SoK：只读 taxonomy、challenges、evaluation pitfalls。	survey/SoK PDF 或摘要；个人笔记。	画 Transformer secure inference 的算子图：MatMul、Softmax、GELU、LayerNorm。；产出：Transformer 算子地图。	必懂：Transformer 为什么比 CNN/MLP 难。；自测：能指出最难的 3 个算子。
37	6h	MPCFormer、Iron、PUMA：读 problem setting、approximations、evaluation。	论文与可用代码 README。	比较‘蒸馏/近似/结构保持’三种路线。；产出：Transformer 早期路线对照表。	必懂：为什么 Transformer 不能简单照搬 CNN 近似套路。；自测：能解释 PUMA 相比 MPCFormer 的改进方向。
38	6h	BOLT、SIGMA：读协议设计、激活/softmax 处理、实验。	BOLT ePrint/repo；SIGMA paper。	整理 soft-max/GELU/LayerNorm 的常见处理方式。；产出：非线性协议清单。	必懂：FSS 路线与传统 MPC 路线有何不同。；自测：能比较 BOLT 与 SIGMA 的优化重点。
39	6h	BumbleBee、SHAFT、NEXUS：读系统总览、关键协议、evaluation。	OpenBumbleBee README；NDSS pages；论文。	把 constant-round、non-interactive、communication-friendly 三条路线标出。；产出：2025 前沿路线图。	必懂：‘更快’到底依赖哪些假设。；自测：能指出三篇论文最不可直接横比的地方。
40	6h	BLB（Breaking the Layer Barrier）、Marill、PrivTF / SecureTLM：读问题定义、核心优化、实验。	BLB ePrint/USENIX；Marill；PrivTF；SecureTLM。	从 operator fusion、conversion minimization、MPC reduction 三个视角整理。；产出：LLM/PTI 问题框架 v1。	必懂：为什么 conversion/truncation 会吞掉大部分通信。；自测：能讲清 BLB 为什么值得重点看。
41	6h	MPCViT、CipherPrune、Mosformer（选读），只看题目所指向的问题和 evaluation setting。	对应论文/仓库。	决定你未来半年更关心 NLP Transformer 还是 ViT/通用 block。；产出：应用焦点选择单。	必懂：应用选择如何影响实验复杂度。；自测：能给出你不选某方向的明确理由。

42	5h	回看第 6 周全部内容。	笔记仓库。	做一个 toy Transformer block 的 paper-only cost accounting。；产出：Transformer 成本台账 v1。	必懂：sequence length、hidden size、head 数如何影响成本。；自测：能不看论文推测成本放大项。
43	6h	只补读与你首要瓶颈相关的论文片段。	前沿论文与本地实验脚本。	实验 #2：分解通信/计算/预处理成本。；产出：成本分解图 v1。	必懂：为什么‘总时延’不是唯一有用指标。；自测：能解释主导瓶颈在何处转移。
44	6h	AutoFHE、SHAFT、PUMA 中关于近似/误差的部分。	相关论文。	实验 #3：同一非线性使用 2–3 种近似策略，比较精度与成本。；产出：近似误差表。	必懂：精度损失来自近似本身还是量化/截断。；自测：能从结果反推近似是否值得。
45	6h	CHET、EVA、BLB、LOHEN 中关于布局/融合/层级优化的部分。	论文与可用代码。	实验 #4：改变 packing/layout 或算子融合边界，观察 proxy 成本。；产出：布局/融合实验记录。	必懂：表示布局为什么会决定系统效率。；自测：能举例说明同一 matmul 的不同打包方式差异。
46	6h	Cheetah、CrypTFlow2、Gazelle 中 conversion/linear-nonlinear 划分部分。	论文。	实验 #5：只改协议切换点，其他不变。；产出：conversion sweep 结果。	必懂：为什么‘少切一次’可能比‘优化一个协议’更值钱。；自测：能用数据支持这一判断。
47	6h	Transformer 论文中关于 batch size / sequence length 的主实验。	BumbleBee/SHAFT/NEXUS/PICE 相关 sections。	实验 #6：对 toy block 做 seq len / hidden dim 扫描。；产出：尺度敏感性曲线。	必懂：哪个维度最容易让方案失效。；自测：能给出复杂度与观测结果的一致解释。
48	6h	Piranha/CryptGPU/Concrete GPU acceleration 文档回看。	GPU 相关 docs。	若有 GPU 就做一次小实验；没有则做“为何此实验值得 GPU”的设计说明。；产出：GPU 可行性说明。	必懂：GPU 是否真的帮到你的当前主线。；自测：能判断何时该申请 GPU 资源。
49	5h	整合 Week 7。	实验日志与图表。	形成 3 个候选 research question，每个都配 baseline 与失败风险。；产出：候选选题单 v1。	必懂：好问题与好实验之间的对应关系。；自测：每个问题都能说清‘为什么现在做’。
50	6h	回看最相关的 6–8 篇论文。	你的高相关论文池。	选定 1 个主问题 + 1 个备选问题。；产出：选题决策记录。	必懂：问题定义是否足够窄。；自测：能用一句话定义题目。
51	6h	读所选问题对应论文的 evaluation/setup/limitations。	相关论文与 artifact 文档。	确定 baseline、数据集、指标、硬件与威胁模型。；产出：研究设计表 v1。	必懂：baseline 为何公平。；自测：能解释每个 baseline 的存在必要性。
52	6h	补读框架文档中与你计划直接相关的部分。	MP-SPDZ/OpenFHE/Concrete/SPU/Opacus/BumbleBee 对应 docs。	把未来 4 周实验拆成可执行任务，产出执行 backlog。	必懂：第一阶段最小可行验证是什么。；自测：能在 1 周内启动最小实验。

53	6h	回看所有 bottleneck/ablation 结果。	本地图表与日志。	写 3 页 research memo：问题、洞察、方法、风险。；产出：3 页研究备忘录。	必懂：你的贡献点到底在协议、系统还是编译层。；自测：能明确拒绝‘太大而空’的题目。
54	6h	整理 50+ 论文图谱。	Zotero/Obsidian/Notion 任一。	把论文按 primitive、operator、system、application 四层连边。；产出：阅读图谱成图。	必懂：哪些论文是必读核心，哪些是按题检索。；自测：能给新同学讲清这张图。
55	5h	回看整个 56 天计划与产出。	所有笔记。	做一次 30 分钟口头答辩：讲路线、讲选题、讲实验。；产出：口头答辩录像/提纲。	必懂：你是否已经从‘看懂’进入‘能批判比较’。；自测：能不用看稿讲清自己的主线。
56	5h	不新增论文；复盘全部。	所有文档。	列出接下来 4 周的即时行动项与风险控制。；产出：Bootstrapping 收官文档。	必懂：还缺哪些关键能力。；自测：能给导师提交一份像样的开题前准备报告。

实验路线

E1: MP-SPDZ 微基准

目标：建立算子成本直觉。依赖：MP-SPDZ Getting Started / Protocols / Machine Learning docs。数据：合成向量与矩阵。配置：至少两类协议、多个维度。失败替代：降维度或只保留 add/mul/compare/truncate 四类算子。适合本地 CPU。

E2: MP-SPDZ 小模型推理

目标：跑通 PyTorch 接口或官方小模型。依赖：torch_mnist_dense 等示例。数据：MNIST 或 toy MLP。失败替代：只跑官方示例，不自己导模型。适合本地 CPU。

E3: OpenFHE/SEAL 算子基准

目标：理解 CKKS 的 mul/rotate/rescale/keyswitch 成本。依赖：OpenFHE examples、SEAL examples。失败替代：只跑最小示例并记录参数变化。适合本地 CPU。

E4: Concrete ML FHE 与模拟

目标：跑 toy model 的 compile/simulate/FHE predict。依赖：Concrete ML Quickstart、Prediction with FHE、Debugging docs。失败替代：只做 simulate。适合本地；大参数 sweep 更适合服务器。

E5: MPC-only vs HE-only vs Hybrid 对比

目标：在同一 toy MLP/CNN 上做公平比较。依赖：前四个实验的脚本。失败替代：做 proxy benchmark，不追完整端到端。小规模本地可做，中规模服务器更稳。

E6: Transformer block 成本台账

目标：对 MatMul/Softmax/GELU/LayerNorm 做 paper-only 或 proxy benchmark。依赖：survey、BumbleBee/SHAFT/NEXUS/BLB。失败替代：只做 cost accounting。适合本地。

E7: 选题前消融

目标：针对近似、转换、打包、seq len 做消融。依赖：AutoFHE/LOHEN/BLB 等论文。失败替代：保留 1–2 个最关键变量。小规模本地，大 sweep 服务器。

E8: 研究设计最小验证

目标：为最终主问题做 1 个最小可行验证。依赖：你最终选择的平台。失败替代：用 proxy 指标和 toy setting 先验证方向。视具体题目决定是否需要服务器/GPU。

每日笔记模板

```
# 日期:
# 今日主题:
# 今日投入时长:

## 1. 今天要回答的核心问题
- Q1:
- Q2:
- Q3:

## 2. 阅读记录
- 论文/文档:
- 只读了哪些 section:
- 哪个总览图/主结果表最关键:
- 作者真正解决的瓶颈是什么:
- 威胁模型是什么:
- 哪些比较是不公平的:

## 3. 代码/框架学习
- 看的位置:
- 关键模块:
- 我仍然不懂的函数/类/脚本:

## 4. 实验记录
- 目标:
- 配置:
```

```
- 数据:
- 结果:
- 失败:
- 我认为失败原因是:

## 5. 今天形成的判断
- 哪个算子最贵:
- 哪个转换最痛:
- 哪个近似最可疑:
- 哪个 baseline 必须纳入:

## 6. 研究感问题
- 如果我改这里，会影响什么:
- 我能否提出一个更公平的比较:
- 我今天最像“研究”的一条想法是:

## 7. 自测
- 我能否不用看笔记讲清今天的系统/论文:
- 我能否解释性能来源而不只是复述数字:
- 我能否说清作者没做什么:

## 8. 明天的最小行动
- 必做 1:
- 必做 2:
```

压缩版计划（3–5 小时/天）

- 改成 10–12 周节奏，保留顺序不变：经典论文 $ ightarrow$ MP-SPDZ $ ightarrow$ HE $ ightarrow$ Hybrid $ ightarrow$ Transformer $ ightarrow$ 选题。
- 被压缩内容：重复阅读、GPU/硬件路线、大型仓库深度复现、HE 多方案扩展阅读、ViT/多模态支线。
- 绝对不能删：MP-SPDZ 实操、至少一种 HE 库实操、一次公平对比、一次 bottleneck memo、一次选题 memo。
- 能力损失：你会更少碰到系统工程细节，也更难在短期内判断大模型/长序列路线的真实可复现性。

服务器配置建议

档位	最低可用	推荐	较舒适
CPU	8c/16t	16c/32t	32c/64t 或双机
内存	32 GB	64–128 GB	128–256 GB
磁盘	300 GB SSD	1 TB NVMe	2 TB NVMe+
GPU	可无；有 12 GB 更好	1×24 GB	1×48 GB 或 2×24 GB
适合实验	MPC/HE 小模型与微基准	中等规模 sweep、Concrete GPU、SPU/OpenBumbleBee 尝试	大 sweep、LLM toy/较重 artifact、GPU 路线

50+ 论文附录

#	论文	类别	解决问题	核心技术	时机	关联
1	ABY (NDSS 2015)	基础协议/混合协议	高效 mixed-protocol 2PC 框架	算术/布尔/Yao 三种表示与高效转换	第 1 周	高
2	MASCOT (CCS 2016)	MPC 基础	恶意安全算术 MPC 的高效预处理	基于 OT 的恶意安全乘法预处理	第 1–2 周	高
3	SecureML (IEEE S&P 2017)	MPC PPML	可扩展隐私保护 ML 训练/推理	two-server sharing + 线性/逻辑回归/NN 协议	第 1 周	高
4	MiniONN (ACM CCS 2017)	MPC 推理	通用神经网络转 oblivious 推理	网络转换 + 常用层专用协议	第 1 周	高
5	CKKS (ASIACRYPT 2017)	HE 基础	近似数同态计算	approximate HE, scale/rescale	第 3 周	高
6	Faster FHE Bootstrapping (ASIACRYPT 2016)	HE 基础	大幅降低 bootstrapping 代价	快速 bootstrapping	第 3 周	中
7	ABY3 (ACM CCS 2018)	3PC 框架	三方 mixed-protocol ML 框架	3PC + mixed shares + truncation	第 1 周	高
8	Gazelle (USENIX Security 2018)	Hybrid 推理	低时延安全 NN 推理	HE 线性层 + GC 非线性层 + switching	第 1/4 周	高
9	SecureNN (PoPETs 2019)	3PC PPML	高效私有 NN 训练/推理	3PC building blocks	第 1 周	高
10	CHET (PLDI 2019)	HE 编译器	FHE NN 推理编译优化	参数选择/张量布局/方案优化	第 3 周	高
11	LoLa (ICML/PMLR 2019)	HE 推理	低时延 HE 推理	更优线性代数表示/packing	第 3 周	中高

12	EVA (PLDI 2020)	HE 编译器	通用 FHE 向量语言与编译器	IR + optimizing compiler	第 3 周	高
13	MP-SPDZ (ACM CCS 2020)	MPC 工具链	统一高层框架下运行多种协议	多协议/多安全模型后端	第 2 周	极高
14	OpenFHE library (WAHC/ACM 2022)	HE 工具链	统一多方案开源 FHE 库	支持 BFV/BGV/CKKS/FHEW 等	第 3 周	高
15	Chameleon (ePrint 2017)	Hybrid 框架	高效混合 SFE/ML	加法分享 + GC/GMW + 离线随机性	第 1 周	中高
16	XONN (USENIX Security 2019)	GC/结构改造	GC 友好的二值网络推理	XNOR 网络 + 常数轮次	第 1 周	高
17	Delphi (USENIX Security 2020)	Hybrid 推理	神经网络推理加密服务	ML+crypto co-design + hybrid protocol	第 1 周	高
18	CrypTFlow2 (ACM CCS 2020)	2PC 推理	现实规模 2PC 安全推理	comparison/division 优化 + SCI-HE	第 1/4 周	极高
19	FALCON (PoPETs 2021)	3PC 训练/推理	恶意安全 honest-majority 深度学习	3PC malicious with abort	第 5 周	中高
20	ASTRA (ACM CCS 2019)	3PC 基础	高吞吐 3PC over rings	高效 online multiplication	第 5 周	中高
21	FLASH (PoPETs 2020)	4PC/鲁棒 PPML	带 GOD 的四方 PPML	4PC over rings + robust building blocks	第 5 周	中
22	ARIANN (PoPETs 2022)	FSS/低交互	低交互私有深度学习	FSS + trusted dealer	第 5 周	中高
23	SIRNN (arXiv/ePrint 2021)	序列模型推理	RNN 安全推理的数学函数库	lookup-table + mixed-bitwidth	第 5 周	中
24	Cheetah (USENIX Security 2022)	2PC 推理	精瘦快速 2PC DNN 推理	更优 linear/nonlinear protocols	第 1/5 周	极高
25	Piranha (USENIX Security 2022)	GPU 系统	GPU 平台化安全计算	GPU integer kernels + protocol/app layers	第 5 周	高
26	CryptGPU (arXiv 2021)	GPU 系统	GPU 上的 PPML 训练/推理	GPU-friendly MPC primitives	第 5 周	中高
27	Meteor (WWW 2023)	3PC 推理	降低在线通信的 3PC NN 推理	communication-efficient 3PC	第 5 周	中高
28	SecretFlow-SPU (USENIX ATC 2023)	编译器/框架	用户友好且高性能的 PPML 框架	frontend compiler + backend runtime	第 5 周	高
29	CryptoNets (ICML 2016)	HE 推理	加密数据上的 NN 推理	FHE + 平方激活	第 3 周	高

30	Simulating Homomorphic Evaluation of Deep Learning Predictions (CSCML/LATINCRYPT 2019)	HE 分析	用模拟预测 HE 推理行为	noise/accuracy simulation	第 4 周	中高
31	HEAX (ASPLOS 2020)	HE 硬件	FHE 计算架构加速	并行 NTT + pipeline architecture	第 4 或后续	中
32	CoFHE (Frontiers in Electronics 2023)	软硬件协同	FHE-MLaaS 软硬件协同设计	多方案选择 + accelerator design	第 4 周	中
33	AutoFHE (USENIX Security 2024)	HE 优化	自动化适配 CNN 到 FHE	mixed-degree activations + bootstrap placement	第 4/7 周	高
34	LOHEN (USENIX Security 2025)	HE/多方案优化	层级优化 NN over encrypted data	layer-wise scheme selec-tion/switching	第 4/7 周	高
35	Poseidon (HPCA 2023)	HE 硬件	实用 FHE accelerator	HBM+FPGA + CKKS-like ops	后续	中
36	PrivFT (arXiv 2019)	HE NLP	文本分类的 HE 推理/训练	CKKS + GPU implementation	第 4/后续	中
37	MPCFormer (ICLR/OpenReview 2023)	Transformer MPC	可落地的私有 Transformer 推理	approximation + KD	第 6 周	高
38	Iron (NeurIPS 2022)	Transformer MPC	更快的私有 Transformer 推理	更省通信/更快 runtime	第 6 周	高
39	Primer (DAC 2023)	Transformer HE	加密数据上的快速私有 Transformer 推理	HE-friendly transformer optimizations	第 6 周	中高
40	PUMA (arXiv/OpenReview 2023)	LLM MPC	LLaMA-7B 级 secure inference	高质量近似 + faithful Embed-ding/LayerNorm	第 6 周	高
41	BOLT (IEEE S&P 2024)	Transformer MPC	准确高效 Transformer 推理	专用协议优化	第 6 周	高
42	SIGMA (PoPETs 2024)	GPT/FSS	Secure GPT inference with FSS	FSS-based protocols for GPT	第 6 周	高
43	NEXUS (NDSS 2025)	Transformer 非交互	非交互 secure transformer inference	one-round/non-interactive design	第 6 周	极高
44	BumbleBee (NDSS 2025)	Transformer 2PC 系统	大 Transformer 的 2PC 推理框架	optimized matmul + activations	第 6 周	极高
45	SHAFT (NDSS 2025)	Transformer 2PC 系统	准确快速 Transformer 推理	constant-round softmax + GELU approximation	第 6 周	极高

46	Breaking the Layer Barrier (USENIX Security 2025)	Hybrid Trans-former	Hybrid CKKS+MPC 私有 Transformer	fine-grained linear operator fusion + conversion minimization	第 6/7 周	极高
47	MPC-Minimized Secure LLM Inference (Marill) (OpenReview/arXiv 2024)	LLM 系统	尽量减少 MPC 的 secure LLM inference	MPC minimization + hybridization	第 6 周	中高
48	PrivTF (IEEE TNSE 2025/2026 online-first 待核)	Transformer MPC	面向安全 NLP 的 Transformer 推理	optimized protocols for secure NLP	第 6 周	中
49	SecureTLM (Information Sciences 2024)	Transformer MPC	不改模型结构的 TLM 私有推理	Softmax/GELU/LayerNorm MPC protocols	第 6 周	中
50	MPCViT (ICCV 2023)	ViT/架构搜索	MPC-friendly ViT 搜索	heterogeneous attention + architecture search	第 6/后续	中
51	CipherPrune (arXiv 2025)	Transformer 扩展性	高效可扩展私有 Transformer 推理	token/pruning style scalability optimization	后续	中
52	Mosformer (ePrint 2025)	恶意安全 Trans-former	大 Transformer 的 3PC/恶意安全推理	malicious-secure 3PC design	后续	中
53	SoK: Private Transformer-Based Model Inference (IACR ePrint 2026)	SoK	系统梳理私有 Transformer 推理	top-to-bottom taxonomy + gap analysis	第 6 周	极高
54	A Survey on Private Transformer Inference (arXiv 2024)	Survey	综述 PTI 进展与挑战	taxonomy + evaluation guidelines	第 6 周	高

结语

这份 LaTeX 源码是最终研究路线的可编译版本。建议用 XeLaTeX 或 LuaLaTeX 编译。